前缀（4 路图像、指令、状态）：前向一次，缓存 KV

动作专家：每个动作块前向 10 次（NFE = 10），复用缓存的前缀

推理：① 以文本预测子任务 $\hat{l}$ → 拼接到前缀 → ② 对动作块去噪

① 子任务预测 $\hat{l}$（自回归文本）

拿起枕头

VLM 主干

ViT ViT ViT ViT



相机视角 o_t：前、后、双腕部

打扫卧室 — 高层指令

q_t — 状态

拿起枕头 — 子任务 $\hat{l}$

② 动作块 A^1（H 步）

a_t a_{t+1} … a_{t+H-1}

10 步之后

Euler 步，δ = 1/10

$A^{\tau+\delta} = A^\tau + \delta\, v_\theta(A^\tau, \tau \mid o_t, \hat{l})$

τ: 0 → 0.1 → … → 1

v_θ

动作专家

×10

$A^{\tau+\delta}$

噪声 $A^0 \sim N(0, I)$

+ 流时间 τ（adaRMSNorm）

某一动作维度 A^τ 在回环中的变化

